



Passos para o Deploy

Cloud and Cognitive Environments



Google Colab: Geração do modelo árvore

▼ Parte 2

```
[20] query_sql = """
      SELECT
          *
          FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2018`
          LIMIT 10000
      """

      query_job = clientbq.query(query_sql)
      dados_dataset = query_job.to_dataframe()
```

```
[21] dados_dataset['tip_amount'] = pd.to_numeric(dados_dataset['tip_amount'])
```

```
[22] tip_y = dados_dataset['tip_amount']>0
      tip_n = (dados_dataset['tip_amount']<0) | (dados_dataset['tip_amount']==0)
```

```
[23] dados_dataset.loc[tip_y, 'FLG_TIP']='Y'
      dados_dataset.loc[tip_n, 'FLG_TIP']='N'
```

```
[24] dados_dataset=dados_dataset[['FLG_TIP', 'data_file_year', 'dropoff_location_id', 'pickup_location_id', 'total_amount', 'tolls_amount', 'mta_tax', 'payment_type']]
```

Google Colab: Geração do modelo árvore

```
19 from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score

X = dados_dataset.drop('FLG_TIP',axis=1)
Y = dados_dataset['FLG_TIP']

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2, random_state=42)

ar = DecisionTreeClassifier()
ar.fit(X_train, Y_train)

predict = ar.predict(X_test)

precisão = accuracy_score(Y_test, predict)
print(f'A precisão do modelo de Arvore é: {precisão}')
```

➡ A precisão do modelo de Arvore é: 0.993

```
08 [26] import joblib

joblib.dump(ar, 'model.pkl')

['model.pkl']
```

Azure: Criar grupo de recursos



[Página inicial](#) > [Criar um recurso](#) > [Marketplace](#) > [Grupo de recursos](#) >

Criar um grupo de recursos

Básico Marcações Revisar + criar

Grupo de recursos – Um contêiner que armazena recursos relacionados a uma solução do Azure. O grupo de recursos pode incluir todos os recursos para a solução ou apenas os recursos que você deseja gerenciar como um grupo. Você decide como deseja alocar recursos para os grupos de recursos com base no que é mais conveniente para sua organização. [Saiba mais](#)

Detalhes do projeto

Assinatura * ⓘ

Azure for Students ▼


Grupo de recursos * ⓘ

Detalhes do recurso

Região * ⓘ

(US) East US ▼

Azure: Criar workspace do Azure ML Studio

 Microsoft Azure

Pesquisar recursos, serviços e documentos (G+/I)

[Página inicial](#) >

Azure Machine Learning

Fiap-Faculdade de Informática e Administração Paulista (fiap.com.br)

+ Criar

Excluído recentemente


Gerenciar a exibição

Atualizar


Exportar para CSV

Abrir a consulta

Atribuir marcações

 Novo workspace

Para projetos e equipes de ML

 Novo registro

Para compartilhar ativos de ML entre workspaces

Tipo igual a tudo

Grupo de recursos igual a tudo

Localização igual a tudo

Adicionar filtro

	Grupo de recursos ↑↓	Tipo ↑↓	Loc.
<input type="checkbox"/>	azurefreecostfiap	freecostfiap	Workspace do Azure Machine Learning

Azure: Criar workspace do Azure ML Studio

[Página inicial](#) > [Azure Machine Learning](#) >

Azure Machine Learning

Criar um workspace do Machine Learning

[Básico](#) [Rede](#) [Criptografia](#) [Identidade](#) [Marcas](#) [Examinar + criar](#)

Detalhes do recurso

Cada workspace deve ser atribuído a uma assinatura do Azure, que é onde ocorre a cobrança. Você usa grupos de recursos como pastas para organizar e gerenciar recursos, incluindo o espaço de trabalho que está prestes a criar.

[Saiba mais sobre os grupos de recursos do Azure](#)

Assinatura *	<input type="text" value="Azure for Students"/>
Grupo de recursos *	<input type="text"/>

[Criar novo](#)

Detalhes do workspace

Defina as configurações básicas do workspace, como conexão de armazenamento, autenticação, contêiner e muito mais.

[Saiba mais](#)

Nome *	<input type="text"/>
Região *	<input type="text" value="East US"/>
Conta de armazenamento *	<input type="text"/>
	Criar
Cofre de chaves *	<input type="text"/>
	Criar
Application Insights *	<input type="text"/>
	Criar
Registro de contêiner	<input type="text" value="testecogflap"/>
	Criar

[Examinar + criar](#)

[< Anterior](#)

[Próximo: Rede](#)

Azure: Iniciar Estúdio dentro do Azure ML criado

Página inicial > Azure Machine Learning >

Azure Machine Lea... «

Fiap-Faculdade de Informática e Administração Pa...

+ Criar ▾ ...

Filtrar por qualquer campo...

Nome ↑

azurefreecostfiap ...

Visão geral

- Log de atividade
- IAM (Controle de acesso)
- Marcações
- Diagnosticar e resolver problemas
- Eventos

Configurações

- Rede
- Propriedades
- Bloqueios

Monitoramento

- Alertas
- Métrica
- Configurações de diagnóstico
- Logs

Automação

- CLI / PS
- Tarefas (versão prévia)
- Exportar modelo

Suporte + solução de problemas

- Integridade do recurso

Buscar

Baixar config.json Excluir

Fundamentos

Grupo de recursos : [freecostfiap](#)

Localização : South Central US

Assinatura : [Azure for Students](#)

Armazenamento : [azurefreecost1287186453](#)

URL da Web do Studio : <https://ml.azure.com?tid=11d8bfe7-808b-4549-ba10-c9c304e...>

Registro de Contêiner : [freecostfiap](#)

Key Vault : [azurefreecost0419457488](#)

Application Insights : [azurefreecost0394993113](#)

URI de acompanhamento do MLflow : [azureml/southcentralus.azureml.ms/mlflow/v1.0/subscrip...](#)

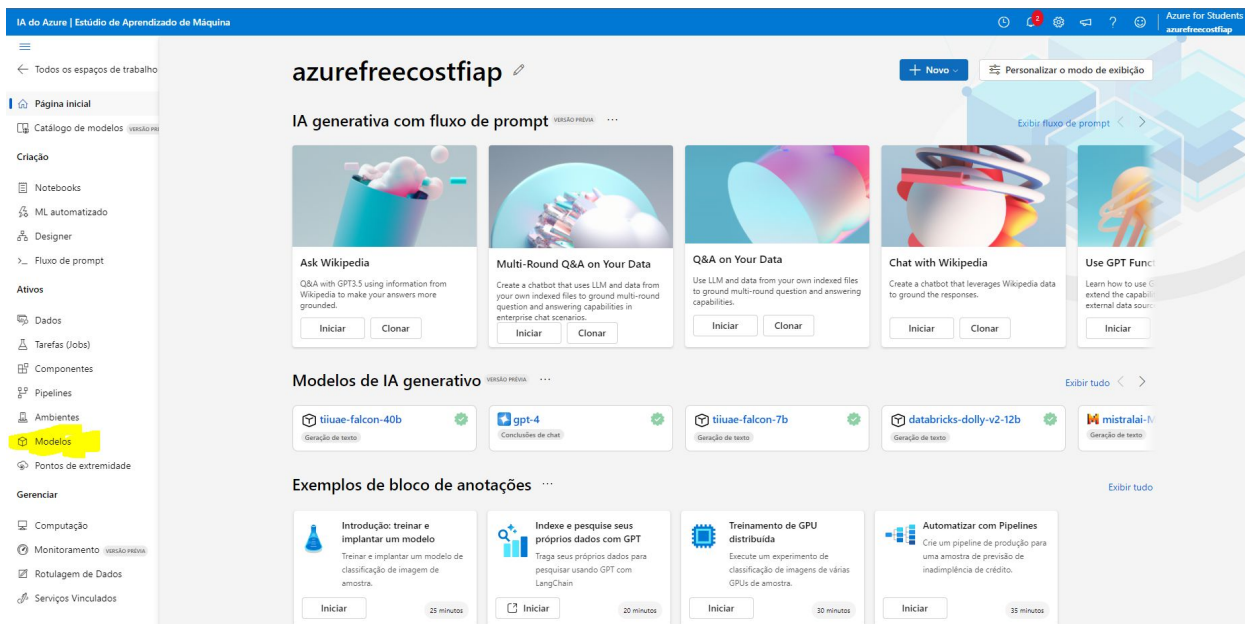
Exibição JSON

Trabalhar com seus modelos no Estúdio do Azure Machine Learning

O Azure Machine Learning Studio é um aplicativo Web em que você pode criar, treinar, testar e implantar modelos de ML. Inicie-o agora para começar a explorar ou learn more about the Azure Machine Learning studio?

Iniciar o estúdio

Azure ML Studio: Registrar Modelo



The screenshot displays the Azure ML Studio web interface. The top navigation bar is blue with the text "IA do Azure | Estúdio de Aprendizado de Máquina" and a user profile icon labeled "Azure for Students azurefreecostfiap". The left sidebar contains a menu with the following items: "Página Inicial", "Catálogo de modelos", "Criação", "Notebooks", "ML automatizado", "Designer", "Fluxo de prompt", "Ativos", "Dados", "Tarefas (Jobs)", "Componentes", "Pipelines", "Ambientes", "Modelos" (highlighted with a yellow box), "Pontos de extremidade", "Gerenciar", "Computação", "Monitoramento", "Rotulagem de Dados", and "Serviços Vinculados". The main content area is titled "azurefreecostfiap" and features a "Novo" button and a "Personalizar o modo de exibição" button. Below this, there are three sections: "IA generativa com fluxo de prompt" with five cards for "Ask Wikipedia", "Multi-Round Q&A on Your Data", "Q&A on Your Data", "Chat with Wikipedia", and "Use GPT Function"; "Modelos de IA generativo" with five cards for "tiuae-falcon-40b", "gpt-4", "tiuae-falcon-7b", "databricks-dolly-v2-12b", and "mistralai-M"; and "Exemplos de bloco de anotações" with four cards for "Introdução: treinar e implantar um modelo", "Índex e pesquise seus próprios dados com GPT", "Treinamento de GPU distribuída", and "Automatizar com Pipelines". Each card includes a brief description and an "Iniciar" button.

IA do Azure | Estúdio de Aprendizado de Máquina

azurefreecostfiap

+ Novo Personalizar o modo de exibição

IA generativa com fluxo de prompt

Ask Wikipedia

Q&A with GPT-3.5 using information from Wikipedia to make your answers more grounded.

Iniciar Clonar

Multi-Round Q&A on Your Data

Create a chatbot that uses LLM and data from your own indexed files to ground multi-round question and answering capabilities in enterprise chat scenarios.

Iniciar Clonar

Q&A on Your Data

Use LLM and data from your own indexed files to ground multi-round question and answering capabilities.

Iniciar Clonar

Chat with Wikipedia

Create a chatbot that leverages Wikipedia data to ground the responses.

Iniciar Clonar

Use GPT Function

Learn how to use GPT Function to extend the capabilities of your chatbot by integrating external data sources.

Iniciar

Modelos de IA generativo

tiuae-falcon-40b

Geração de texto

gpt-4

Conclusões de chat

tiuae-falcon-7b

Geração de texto

databricks-dolly-v2-12b

Geração de texto

mistralai-M

Geração de texto

Exemplos de bloco de anotações

Introdução: treinar e implantar um modelo

Treinar e implantar um modelo de classificação de imagem de amostra.

Iniciar 25 minutos

Índex e pesquise seus próprios dados com GPT

Taga seus próprios dados para pesquisar usando GPT com LangChain.

Iniciar 20 minutos

Treinamento de GPU distribuída

Execute um experimento de classificação de imagens de várias GPUs de amostra.

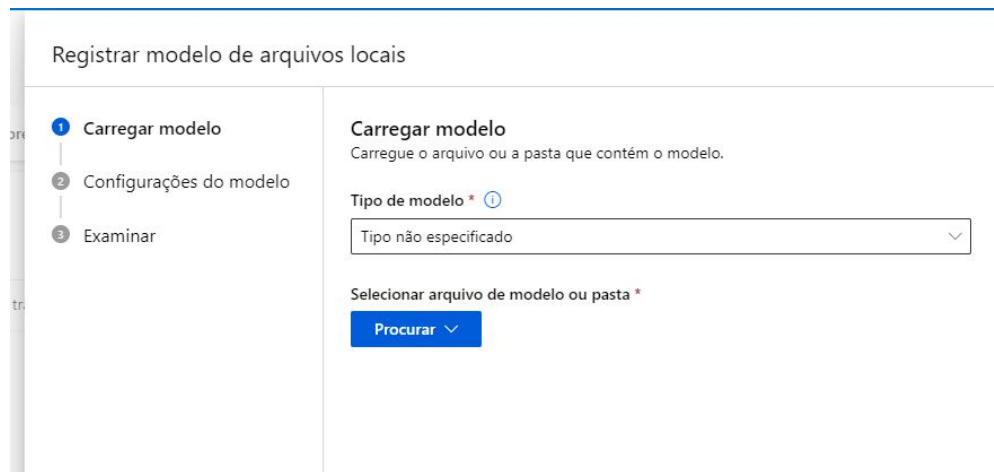
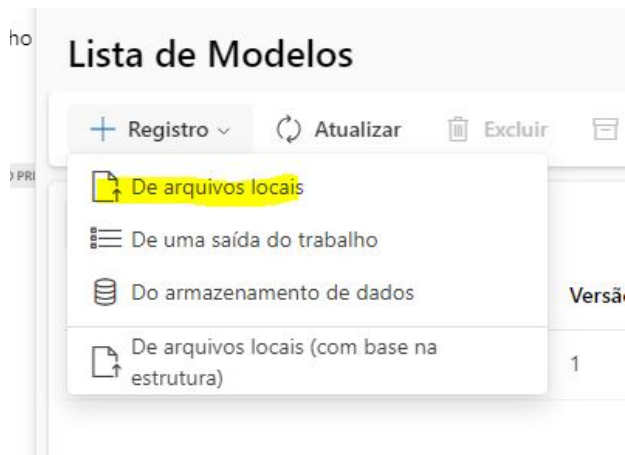
Iniciar 30 minutos

Automatizar com Pipelines

Crie um pipeline de produção para uma amostra de previsão de inadimplência de crédito.

Iniciar 35 minutos

Azure ML Studio: Registrar Modelo



Azure ML Studio: Deploy Modelo

model:1 ☆

Detalhes Versões Artefatos Pontos de extremidade Trabalhos Dados Conjun

Atualizar Arquivar Implantar Compartilhar modelo

Atributos

Nome
model

Versão
1

Criado em
Dec 7, 2023 10:14 PM

Criado por

Ponto de extremidade em tempo real
Implante o modelo usando o assistente do ponto de extremidade em tempo real

Ponto de extremidade do lote
Implante o modelo usando o assistente de ponto de extremidade em lote

Serviço Web
Implantar em um serviço Web (somente para modelos baseados em estruturas)

Tipo de computação ⓘ

☒ Gerenciado ☐ Kubernetes

Tipo de autenticação ⓘ

☐ Autenticação baseada em token ☒ Autenticação baseada em chave

Atualizar Opções de exibição

sklear

Nome	Versão	Marcas
sklearn-1.0:20	20	OpenV
✓ sklearn-1.1:19	19	OpenV

Azure ML Studio: Script de Inferência

Antes de iniciar o deploy, não esquecer de inserir o script de inferência, pois ele será a saída do modelo desenvolvido. No caso foi utilizado o “score_json.py”

Implantar model:1

- ✓ Ponto de extremidade
- ✓ Modelo
- ✓ Implantação
- ✗ Código + ambiente
- 5 Computação

Código e ambiente para inferência

Para o modelo selecionado, você precisa fornecer pelo menos um script Python de pontuação e um ambiente. [Saiba mais sobre como preparar o código e o ambiente de inferência](#)

Selecione um script de pontuação para inferência * ⓘ

Navegar

Script(s) opcional(s) ⓘ

Navegar



Azure ML Studio: Script de Inferência

```
1 import os
2 import logging
3 import json
4 import numpy as np
5 import joblib
6 import pandas as pd
7 from flask import Flask, jsonify, request
8
9 class NpEncoder(json.JSONEncoder):
10     def default(self, obj):
11         if isinstance(obj, np.integer):
12             return int(obj)
13         elif isinstance(obj, np.floating):
14             return float(obj)
15         elif isinstance(obj, np.ndarray):
16             return obj.tolist()
17         else:
18             return super(NpEncoder, self).default(obj)
19
20 app = Flask(__name__)
21 app.json_encoder = NpEncoder
22 global meumodelo
23
24 def init():
25     global meumodelo
26     model_path = os.path.join(os.getenv("AZUREML_MODEL_DIR"), "model.pkl")
27     meumodelo = joblib.load(model_path)
28     logging.info("Init complete")
29
30 def run(raw_data):
31     logging.info("model 1: request received")
32     json_ = json.loads(raw_data)
33     campos = pd.DataFrame(json_)
34
35     if campos.shape[0] == 0:
36         return "Dados de chamada da API estão incorretos.", 400
37
38     independent_cols = ["data_file_year", "dropoff_location_id", "pickup_location_id", "total_amount", "tolls_amount", "mta_tax", "payment_type"]
39     x = campos[independent_cols]
40
41     prediction = meumodelo.predict(x)
42
```



Azure ML Studio: Script de Inferência

```
try:
    predict_proba = meumodelo.predict_proba(x)
    proba_list = predict_proba.tolist() if predict_proba is not None else None
except Exception as ex:
    proba_list = None

ret = json.dumps({
    'prediction': list(prediction),
    'proba': proba_list,
    'author': "Felipe Lemos Scudeller"
}, cls=NpEncoder)

print(ret)
return app.response_class(response=ret, mimetype='application/json')
```

Azure ML Studio: Testando o modelo

1- Selecione seu endpoint
na aba “Pontos de extremidade”

2-Clique em “Testar” conforme figura e
inserir os dados no formato JSON

The screenshot displays the Azure ML Studio interface. On the left, a sidebar contains navigation options: 'Todos os espaços de trabalho', 'Página inicial', 'Catálogo de modelos', 'Criação' (Notebooks, ML automatizado, Designer, Fluxo de prompt), 'Ativos' (Dados, Tarefas (Jobs), Componentes, Pipelines, Ambientes, Modelos), 'Pontos de extremidade' (highlighted), and 'Gerenciar' (Computação, Monitoramento, Rotulagem de Dados, Serviços Vinculados). The main area shows the 'Testar' tab for the endpoint 'azurefreecostfiap-wupqi'. It features a 'Testar' button and a 'Logs' button. Below these, a JSON input field is shown with the following data:

```
{
  "data_file_year": 2018,
  "dropoff_location_id": 164,
  "pickup_location_id": 132,
  "total_amount": 63.06,
  "tolls_amount": 5.76,
  "mta_tax": 0.5,
  "payment_type": 2
},
{
  "data_file_year": 2018,
  "dropoff_location_id": 158,
  "pickup_location_id": 230,
  "total_amount": 19.8,
  "tolls_amount": 0.0,
  "mta_tax": 0.5,
  "payment_type": 1
},
{
  "data_file_year": 2018,
  "dropoff_location_id": 17,
  "pickup_location_id": 125,
  "total_amount": 19.8,
  "tolls_amount": 0.0,
  "mta_tax": 0.5,
  "payment_type": 1
}
```

To the right of the input field, the predicted output is displayed in a structured JSON format:

```
{
  "prediction": [
    {
      "0": "N",
      "1": "Y",
      "2": "Y",
      "3": "Y"
    }
  ],
  "proba": [
    {
      "0": 1,
      "1": 0
    },
    {
      "0": 0,
      "1": 1
    },
    {
      "0": 0,
      "1": 1
    },
    {
      "0": 0,
      "1": 1
    }
  ],
  "author": "Felipe Lemos Scudeller"
}
```